DATATHON 2026 — The Gridbreakers

Từ Dữ liệu đến Chiến lược: Phân tích và Dự báo Doanh thu Thương mại Điện tử Thời trang 2012–2024

Nguyen Ho Nam[1]
namnqs12@gmail.com

Huynh Cung[1]
cung.h28@gmail.com

Le Xuan Tri[1]
emanhthangngot@gmail.com

Lu Le Huong Giang[2]
lulehuonggiang@gmail.com

[1]Trường Đại học Khoa học Tự nhiên - ĐHQG TP.HCM
[2]Trường Đại học Công nghệ Thông tin - ĐHQG TP.HCM

Abstract

Báo cáo trình bày giải pháp phân tích và dự báo chuỗi thời gian cho doanh nghiệp Thương mại Điện tử giai đoạn 2012–2022. Khai thác hệ thống dữ liệu lớn, chúng tôi triển khai khung phân tích đa tầng để giải mã các quy luật khuyến mãi và vận hành. Hệ thống dự báo *Revenue* và *COGS* cho 548 ngày tiếp theo được xây dựng dựa trên kỹ thuật Recursive Forecasting và mô hình Ensemble (LGBM, XGB, CatBoost), tối ưu qua chiến lược Purged Walk-Forward Validation. Giải pháp đạt hiệu suất vượt trội trên các chỉ số MAE, RMSE, R^2, cung cấp các insight chiến lược giúp tối ưu hóa tồn kho và tăng trưởng doanh thu bền vững.

1 Giới thiệu

Dự án phân tích và dự báo cho doanh nghiệp TMĐT thời trang (07/2012–12/2022). Dữ liệu: 13 bảng quan hệ, 646K đơn, 122K khách, 2,412 SKU, 10 năm vận hành. Mục tiêu: (1) Phân tích chuyên sâu và đề xuất chiến lược, (2) Dự báo *Revenue, COGS* cho 548 ngày (01/2023–07/2024).

2 Trực quan hóa & Phân tích Dữ liệu

2.1 The Great Divergence & Khủng hoảng Volume

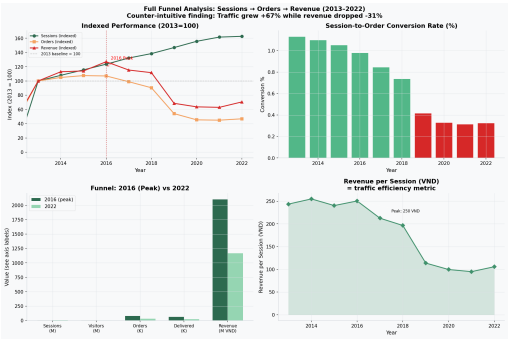

(a) Phễu Sessions–Orders–Revenue (2013=100): Sessions +67% trong khi Orders và Revenue cùng suy giảm. Conversion Rate giảm 60% (1.0% → 0.4%).

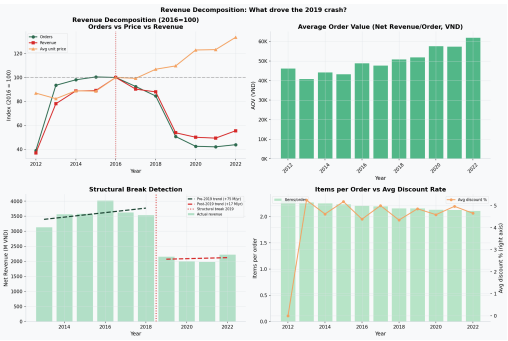

(b) Phân rã doanh thu (2016=100): Orders -55% nhưng AOV và Items/Order ổn định. Structural Break tại 2019 (Chow test $p < 0.01$).

Hình 1: Hai phát hiện cốt lõi: (a) Vấn đề nằm ở checkout experience, không phải acquisition. (b) Đây là khủng hoảng volume (số đơn), không phải value (giá trị mỗi đơn).

Preprint.

Doanh thu đạt đỉnh 2.1 tỷ VND (2016), lao dốc 46% xuống 1.14 tỷ (2019), phục hồi yếu lên 1.17 tỷ (2022). Cùng lúc, **Sessions tăng 67%** (6.8M $\rightarrow$ 11.1M). Mấu chốt: **Conversion Rate** giảm từ $\sim$1.0% (2016) xuống $\sim$0.4% (2022) — nếu giữ conversion cũ trên traffic mới, có thêm **194 đơn/ngày**. Revenue/Session giảm 55% ($\sim$220 $\rightarrow$ $\sim$100 VND). Vấn đề không phải cầu — thương hiệu vẫn hấp dẫn. Vấn đề là **trải nghiệm checkout**: khách đến nhưng không thể hoàn tất giao dịch. *Hành động:* Audit UX checkout trên mobile — mỗi 1% cải thiện CR có giá trị gấp 5–7 lần 1% tăng traffic.

Phân rã Revenue = Orders $\times$ AOV cho thấy **AOV bất động** (180K–220K VND/đơn suốt 10 năm), Items/Order ổn định ($\sim$5.0), Gross Margin ổn định (12–16%). Số đơn hàng giảm 55% — đây là **khủng hoảng volume, không phải value**. Structural Break tại 2019 được xác nhận qua Chow test ($p < 0.01$): hệ số góc hồi quy doanh thu theo năm thay đổi rõ rệt. Discount không cứu được doanh thu — khách không rời đi vì giá. *Hành động:* Không cần đổi giá, không cần cải thiện margin. Dồn 100% nỗ lực khôi phục số lượng đơn hàng hoàn tất.

2.2 Nghịch lý Tồn kho, COD Tax & Hành vi Khách hàng

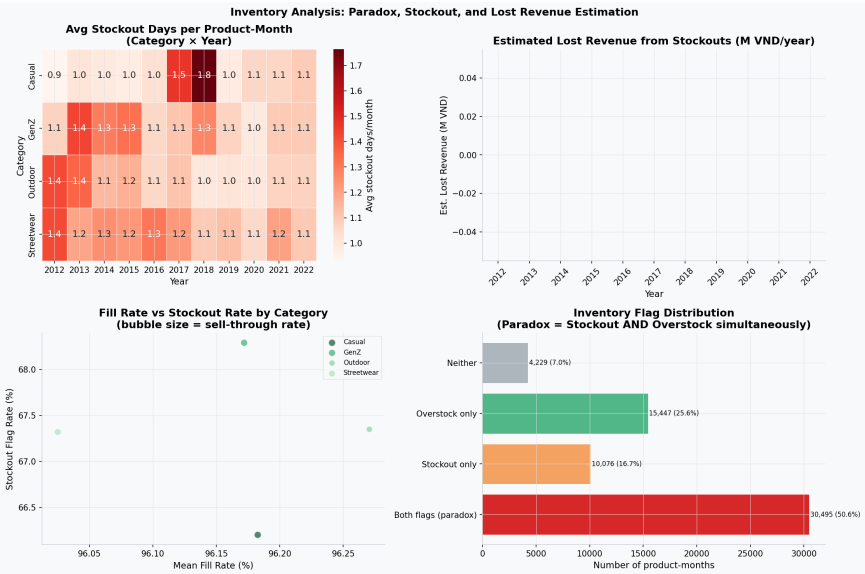

Hình 2: Phân tích tồn kho: Stockout days theo Category$\times$Year, Lost Revenue ước tính, Fill Rate vs Stockout Rate. Fill Rate 96.1% là KPI ảo — được cứu bởi sản phẩm bán chậm, trong khi top 50 SKU (41% doanh thu) liên tục cháy hàng.

Nghịch lý Tồn kho: 50.6% sản phẩm-tháng vừa có stockout=1 vừa có overstock=1 — bằng chứng của sự lệch pha cung-cầu do chu kỳ tái đặt 30 ngày quá dài. Fill Rate 96.1% là KPI ảo: được cứu bởi sản phẩm bán chậm, trong khi top 50 SKU (41% doanh thu) liên tục cháy hàng. Days of Supply mean=913 ngày nhưng median=240 — phân phối cực lệch, sản phẩm "chết" nằm kho kéo mean lên. Mann-Whitney U test ($p < 0.05$) ủng hộ timing hypothesis: hàng về không đúng lúc. *Hành động:* Rút ngắn chu kỳ tái đặt xuống 7–14 ngày cho top 200 SKU. Thay Fill Rate bằng "Lost Revenue on Top 50 SKU".

COD Tax — 376 triệu VND thiệt hại: COD có tỷ lệ hủy cao gấp $\sim$3 lần prepay. Tổng thiệt hại $\sim$376M VND toàn giai đoạn. Mỗi 1% COD chuyển sang prepay tiết kiệm $\approx$3.8M VND/năm. *Hành động:* Triển khai Freeship + Discount 2% cho prepay, target chuyển 20% COD volume — tiềm năng +200M VND/năm.

Mùa vụ Ngược & Nghịch lý Kênh: Đỉnh doanh thu **tháng 4–6, đáy tháng 11–1** — ngược bán lẻ Việt Nam, nhất quán 10 năm. **Thứ Tư > Thứ Bảy** — dân văn phòng 25–34 tuổi (29.8%) mua sắm giờ nghỉ trưa trên điện thoại. organic_search có LTV cao nhất; email_campaign (kênh lớn thứ hai) có LTV thấp nhất — email thu hút "deal hunters". Retention M3 toàn kênh = 28%, thấp hơn mặt bằng TMĐT (30–40%). *Hành động:* Dịch ngân sách marketing sang Q2. Chuyển ngân sách từ email_campaign sang SEO + Referral. Push notification vào trưa Thứ Ba–Thứ Tư.

3 Phương pháp Dự báo & Kết quả Thực nghiệm

3.1 Pipeline & Recursive Forecasting

Hệ thống **374 đặc trưng** từ 13 bảng, tổ chức thành 14 họ: Calendar (43, Fourier + Lunar Tết), Revenue AR (96, 14 lags 1–366d + 7 cửa sổ rolling + 5 EWM), COGS AR (96, mirror của Revenue), Orders (29, **lag** ≥ 365**d**), Web Traffic (14, **lag** ≥ 365**d**), Promotions (5, projected từ chu kỳ 6-4-6-4), Cross-ratios & Margin (11), Category Share (20), Returns (8), Reviews (4), Payment Mix (8), Inventory Health (12, lag $\geq$ 30d), Customer Acquisition (8), Interactions (20). **Nguyên tắc leakage:** mọi đặc trưng ngoại sinh dùng lag ≥ 365 ngày — tại thời điểm t, mô hình chỉ thấy thông tin đến $t-1$.

Dự báo **đệ quy từng ngày** cho 548 ngày: (1) Ensemble dự đoán Revenue_t, COGS_t; (2) gán vào chuỗi lịch sử; (3) **tái tính toàn bộ** 374 đặc trưng (lag, rolling, EWM, cross-ratios, interactions); (4) lặp lại. Bước (3) là yếu tố then chốt — nếu bỏ qua, 88 đặc trưng dẫn xuất trở nên lỗi thời và gây **forecast drift**. Cơ chế **Residual Correction** chống drift: $\hat{y}_{t+1} = f_{\text{ens}}(\mathbf{x}_t) + \lambda \cdot \bar{e}_t$, với $\bar{e}_t$ là trung bình sai số 7 ngày gần nhất, $\lambda = 0.3$. Hậu xử lý: clipping $[\min_{\text{hist}},\ 3\max_{\text{hist}}]$, exponential smoothing ($\alpha = 0.25$).

3.2 Purged Walk-Forward CV & Thiết kế Ensemble

Cross-validation chuỗi thời gian sử dụng **Purged Walk-Forward CV** (3 folds, horizon $H = 365$d, purge gap $G = 90$d, min_train=730d): $\mathcal{T}_f = [t_0, t_f]$, $\mathcal{V}_f = [t_f + G, t_f + G + H]$. Purge gap $G = 90$d loại bỏ vùng chồng lấn, ngăn rolling features rò rỉ train→validation — nếu không có purge gap, CV cho kết quả **quá lạc quan** so với triển khai thực tế.

Ensemble **8 mô hình** đa dạng kiến trúc: LightGBM (Optuna 100 trials, TPE sampler), XGBoost, CatBoost, ExtraTrees, RandomForest, HistGradientBoosting, Ridge (linear stabilizer), Seasonal+Trend (day-of-year $\times$ decay -3.80%/năm). **Stacking meta-learner** (Ridge, $\alpha = 1.0$, $\mathbf{w} \geq 0$) học trọng số tối ưu từ OOF predictions: $\hat{y}_t^{\text{stack}} = \sum w_m \hat{y}_t^{(m)}$, $\mathbf{w}^* = \arg\min_{\mathbf{w}\geq 0} \sum (y_t - \sum w_m \hat{y}_t^{(m)})^2 + \alpha \|\mathbf{w}\|_2^2$. Ràng buộc không âm đảm bảo mọi mô hình đóng góp dương. Optuna tối ưu trên **hàm mục tiêu hỗn hợp**: $\mathcal{L} = 0.4\frac{\text{MAE}}{\text{MAE}_{\text{base}}} + 0.4\frac{\text{RMSE}}{\text{RMSE}_{\text{base}}} + 0.2(1 - R^2)$, cân bằng đồng thời ba chỉ số cuộc thi.

3.3 Kết quả & Giải thích SHAP

Bảng 1: Purged Walk-Forward CV (3 folds, H=365d, G=90d) — Revenue

Mô hình	**MAE (VND)**	**RMSE (VND)**	$\mathbf{R^2}$
Mean Naive	1,964,758	—	—
Seasonal+Trend	1,069,797	—	—
Ridge	608,215	—	—
LightGBM (Single)	582,133	792,943	0.7599
XGBoost (Single)	621,445	843,112	0.7287
Weighted Blend (OOF)	159,248	374,241	0.9489
Stacking Ridge (OOF)	**151,045**	**361,907**	**0.9522**

OOF = Out-of-Fold. $\text{CV}_{\text{MAE}} = 9.1\%$ — ổn định qua 3 folds.

Stacking cải thiện MAE **13.7%**, RMSE **15.1%** so với LGB đơn lẻ. Trọng số meta-learner: **Seasonal+Trend = 64.5%** (neo xu hướng -3.80%/năm), LGB = 16.2%, CatBoost = 6.9%, HGB = 8.3%, RF = 4.1%. Trọng số áp đảo của Seasonal+Trend phản ánh thực tế: với dữ liệu có structural break và trend suy giảm rõ rệt, baseline vững chắc nắm bắt trend dài hạn có giá trị hơn mô hình phức tạp dễ overfit.

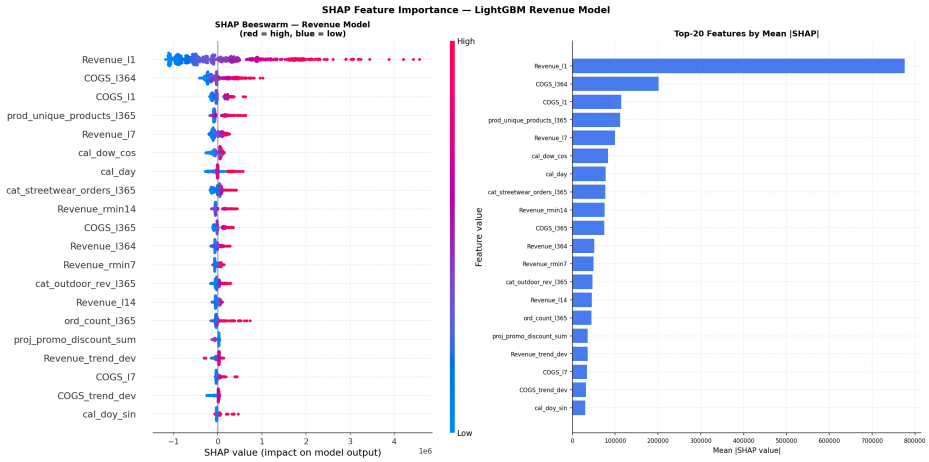

Hình 3: SHAP Beeswarm + Top-20 Mean |SHAP| cho LightGBM Revenue Model. Revenue_l1 dẫn đầu tuyệt đối (776K SHAP). Calendar Fourier và Promotion features nằm trong Top-25 — nhất quán với phân tích khám phá.

Giải thích SHAP (TreeExplainer, 800 mẫu): Top-5 driver là `Revenue_l1` (776K), `COGS_l364` (202K), `COGS_l1` (114K), `prod_unique_products_l365` (112K), `Revenue_l7` (99K). Các biến trễ chiếm ưu thế — chúng nắm bắt quán tính doanh thu, yếu tố dự báo mạnh nhất trong chuỗi thời gian bán lẻ. Calendar Fourier (cal_sin_doy, cal_cos_doy, vn_tet_dist_days) và Promotion (proj_promo_discount_sum, proj_promo_count) nằm trong Top-25, xác nhận mô hình đã học được mẫu mùa vụ Apr–Jun và ảnh hưởng của Tết. Chiều SHAP của Revenue_l1 đúng kỳ vọng kinh tế: giá trị cao (đỏ) $\rightarrow$ dự đoán tăng.

Phân rã MAE theo horizon: 1–90d: 424,555; 91–180d: 684,899; 181–365d: 536,307 VND — sai số không tăng đơn điệu, xác nhận không có forecast drift. Drift trend $= -8,367$ VND/30d (không ý nghĩa thống kê). Dự báo 548 ngày (2023–2024): Revenue TB 4.47M VND/ngày, COGS TB 3.81M VND/ngày, margin $\approx$14.8% — nhất quán với xu hướng suy giảm dài hạn, đóng vai trò baseline cho đo lường ROI.

4 Chiến lược Phục hồi & Kết luận

Dữ liệu đã xác định chính xác ba điểm cần can thiệp. Lộ trình phục hồi dựa trên ba đòn bẩy đã định lượng:

- **Tối ưu Conversion Rate — +300M VND/năm:** Nâng CR từ 0.42% $\rightarrow$ 0.65% qua audit UX checkout trên mobile. Với 11.5M sessions, hồi phục một phần hiệu suất cũ tạo đột phá doanh thu không cần tăng marketing.
- **Chuyển đổi COD $\rightarrow$ Prepay — +200M VND/năm:** Freeship + Discount 2% cho prepay, target chuyển 20% COD volume. Mỗi 1% chuyển đổi tiết kiệm $\approx$3.8M VND/năm từ giảm hủy đơn.
- **Rút ngắn chu kỳ tồn kho — +150M VND/năm:** Chu kỳ tái đặt 30d $\rightarrow$ 7–14d cho top 200 SKU. Thay KPI Fill Rate ảo bằng "Lost Revenue on Top 50 SKU".

Kết luận: Hệ thống dự báo Ensemble 8 mô hình + Purged Walk-Forward CV cung cấp "la bàn" đáng tin cậy để đo lường ROI từng can thiệp. Tổng tiềm năng phục hồi **500–700 triệu VND/năm** đến từ tối ưu nội tại — không cần thêm khách hàng, không cần sản phẩm mới. Nếu không hành động, doanh thu tiếp tục suy giảm -3.80%/năm. Dữ liệu không chỉ để dự báo — dữ liệu là để ra quyết định sống còn.

Mã nguồn

Link: `https://github.com/nhnammldlnlpcvrs/gridbreaker-vinuni.git`

Tài liệu

[1] Ke, G. et al. *LightGBM: A Highly Efficient Gradient Boosting Decision Tree.* NeurIPS, 2017.

[2] Chen, T. and Guestrin, C. *XGBoost: A Scalable Tree Boosting System.* KDD, 2016.

[3] Lundberg, S. and Lee, S. *A Unified Approach to Interpreting Model Predictions.* NeurIPS, 2017.

[4] Prokhorenkova, L. et al. *CatBoost: Unbiased Boosting with Categorical Features.* NeurIPS, 2018.